

Comsen人工智能实验室——智能体方向招新题目

出题人：龚海心

题目概览

本题目主要从大语言模型（Large Language Model, LLM）在实际应用构建方面出发，尤其是在智能体、工作流、多智能体系统等方面，最终完成一个小项目的构建。主要要求学生掌握LLM API的调用，工作流的设计、搭建，智能体框架的应用及增强检索生成（RAG）。

（必看）提交方式见文档底部 测试提交方式 部分，没按正确方式提交将失去成绩

有问题请咨询群内龚海心

基础部分

任务0：开发环境配置

首先安装对应版本的Anaconda，然后用conda配置一个python版本为3.11的虚拟环境。

Anaconda配置教程：https://www.bilibili.com/video/BV1y6XGYUEP7/?spm_id_from=333.337.search-car_d.all.click&vd_source=82042c5ec0d573ec86f1d0034801d5a2

```
conda create -n comsen_env python=3.11

conda activate comsen_env

pip install llama-index openai
```

后续如果需要用到别的依赖库，需要自行识别，并用conda进行环境配置。

同时，你还需要一些Python基本编程知识。（这些知识通常在2天内就可以学会）

RUNOOB python教程：<https://www.runoob.com/python/python-tutorial.html>

我们这里强烈推荐使用cursor, Trae等带有AI coding功能的IDE。

- <https://cursor.com/cn> (Cursor)
- <https://www.trae.ai/pricing> (Trae)
- （均需要科学上网。如果不知道怎么科学上网，请咨询管理获得替代方案）

任务1：智能体工作流搭建基础概念入门

在开始构建智能体前，你需要学习并了解智能体相关的基本概念。

任务要求

1. 学习并简要解释一下概念：
 - 应用程序接口（API）

- 大语言模型 (LLM)
- 提示词工程 (Prompt Engineering)
- 系统提示词 (System Prompt)
- 智能体 (Agent)
- 工具调用 (Function Tool Calling)
- 智能体工作流 (Agentic Workflow)
- 思考-行动智能体 (ReActAgent)
- 增强检索生成 (Retrieval-augmented generation, RAG)

参考资料：

- <https://waytoagi.feishu.cn/wiki/QPe5w5g7UisbEkkow8XcDmOpn8e> (WaytoAGI|通往AGI之路 开源知识库)
- <https://zhuanlan.zhihu.com/p/17879967839> (Google 智能体白皮书)
- <https://www.anthropic.com/engineering/building-effective-agents> (Anthropic-Building effective agents)

任务2：调用LLM API，实现一个有上下文记忆的对话程序

LLM是当下智能体构建的核心。在开始构建一个智能体或者一个工作流前，我们首先要在程序中接入一个LLM。

任务要求

1. 注册并获取一个Deepseek API Key

- <https://platform.deepseek.com/usage> (Deepseek 开发平台)
- <https://api-docs.deepseek.com/zh-cn/> (Deepseek 官方文档)

2. 在Python中调用Deepseek的LLM API，实现一个“有记忆”的人工智能对话程序。这里要求调用Deepseek-R1模型，需要展示出LLM的思考过程。（后续任务可以改用Deepseek V3模型）

效果示例：

=====

 你：你好,我是海心

 AI：

 AI正在思考中...

【思考】

用户的消息是“你好,我是海心”，这是一个简单的问候和自我介绍。用户名为“海心”，这可能是他们的名字或昵称。作为智能助手，我需要分析这个情境：

- 这是一个社交互动的开场白，用户没有提出具体问题或请求，因此我的回应应该以礼貌和友好为主。
- 我应该先回应问候，介绍自己，并表达欢迎，以建立良好的对话氛围。
- 然后，我可以主动提供帮助，引导用户说明他们的需求，因为助手的核心功能是协助用户解决问题。
- 推理过程：用户可能只是想测试交互或开始一个对话，所以我需要保持开放和 inviting 的语气。
- 得出结论：我的回应应包括问候、自我介绍和帮助提议。

你好海心！很高兴认识你。我是智能助手，随时准备帮助你。有什么我可以为你做的吗？

 你：你还记得我是谁吗

 AI：

 AI正在思考中...

【思考】

用户的问题“你还记得我是谁吗”是在询问我是否基于之前的对话记住他们的身份。回顾对话历史，用户的第一条消息是“你好，我是海心”，其中他们明确介绍了自己为“海心”。作为智能助手，我在当前会话中能够保留短期上下文，因此我可以确认记得用户。这有助于建立信任和对对话的连续性。我的回应应该友好、肯定，并引导用户回到提供帮助的主题上，以保持交互的 productive。

是的，海心，我记得你！我们刚刚开始对话，你介绍过自己。很高兴能继续帮助你。有什么具体的事情我可以为你做吗？

温馨提醒

1. Deepseek官方文档包含了丰富的信息。
2. 可以使用AI来辅助编程，但你要知道程序运行原理。

加分项（如果你完成下面这些要求，你将得到更高的评价）

1. 在模型输出的时候使用“Token流式输出”。
2. 使用LlamaIndex智能体框架完成该任务。

<https://docs.llamaindex.ai/en/stable/>（LlamaIndex官方文档）

任务3：创建一个简单的工作流

在完成了基础的智能体认知和“有记忆”的对话程序后，我们进一步进入 **智能体工作流（Agentic Workflow）** 的实践。本任务的目标是让你学会如何把 **LLM的思考能力** 与 **外部工具调用** 结合起来，从而实现一个 **能回答实时信息问题** 的小型工作流。

智能体设计教程：<https://zhuanlan.zhihu.com/p/690202723>

任务要求

1. 首先实现一个函数，能调用DuckDuckGo 搜索工具（主要是使用DDGS库），将其构建成一个工具。这个工具，可以将检索结果（标题+摘要+链接）返回给AI作为候选材料。

DDGS教程：https://blog.csdn.net/qg_40999403/article/details/149640626

2. 实现一个智能体工作流。我们构建的工作流需要包含以下几个环节

1. 用户输入问题

- 用户向系统提出自然语言问题。
- 例如：“今天北京的天气怎么样？”、“请帮我找一下最新的人工智能新闻。”

2. AI总结查询关键词

- LLM先对用户问题进行分析，抽取出关键查询词，避免用户输入长而复杂的句子导致检索效果差。

- 例如：输入“请帮我找一下最新的人工智能新闻。” → LLM输出关键词 `人工智能 最新 新闻`。

3. 调用DuckDuckGo搜索工具

- 将检索结果（标题+摘要+链接）返回给AI作为候选材料。

4. AI总结回答

- 基于搜索结果，LLM对信息进行总结和加工，最终返回一段简洁、自然的答案。

- 例如：

“最近的人工智能新闻包括：OpenAI发布了新模型，Google DeepMind公布了新的研究成果，国内也有企业在XR智能体方面进展明显.....”

效果示例：

```
🤖 智能搜索智能体系统 - DDGS + DeepSeek AI增强版
=====
功能说明：
1. 自动提取用户问题关键词
2. 使用DDGS搜索相关信息
3. DeepSeek AI智能总结生成答案
4. 保存对话历史记录
5. 显示详细搜索结果
=====
✅ 已从配置文件加载DeepSeek API密钥
✅ DDGS搜索工具已初始化
✅ DeepSeek AI已初始化

👤 请输入您的问题（输入 'quit' 退出）：请帮我找一下最新的人工智能新闻

=====
🚀 智能搜索智能体开始工作...
=====
👤 用户问题：请帮我找一下最新的人工智能新闻
-----
🧠 正在分析用户问题：请帮我找一下最新的人工智能新闻
🔑 提取的关键词：新闻 最新 人工智能
-----
🔍 正在使用DDGS搜索：新闻 最新 人工智能
✅ 找到 5 个搜索结果
-----
🤖 正在调用DeepSeek AI分析搜索结果...
✅ DeepSeek AI回答生成成功

🤖 AI答案：
-----
根据您的最新人工智能新闻的需求，我整理了以下专业信息渠道供您参考：

🇨🇳 **实时行业动态**
1. **AIHub工具导航** - 每日更新行业新闻、产品发布和研究进展，适合开发者与研究者追踪前沿趋势
2. **AI工具导航站** - 汇聚全球AI技术突破、应用案例和企业动态，涵盖政策法规和学术研究
```



深度分析门户

3. **智能网（中文门户）** - 提供市场前景分析和企业跟踪报道，注意其部分内容更新频率需核实（摘要显示2021年数据）

4. **AI News** - 5天前持续更新的深度分析和趋势洞察，涵盖技术应用与市场动态



每日快讯类

5. **AIbase日报** - 每日三分钟精选资讯，适合快速掌握行业动态并获取独家解读



使用建议：

- 如需实时追踪：优先选择AIHub和AI工具导航站
- 关注深度分析：推荐AI News和智能网（建议核实日期）
- 每日碎片化阅读：AIbase日报最高效

（注：由于搜索结果未提供具体链接，建议通过平台名称直接搜索访问。部分渠道的更新时效性需您实际访问时确认）

希望这些渠道能帮助您及时获取有价值的AI行业资讯！

=====

加分项

1. workflows中的每个Agent都有结构化的提示词和标准化的格式输出。

- 结构化提示词系统论述：<https://langgptai.feishu.cn/wiki/ASXOwDbTEiH9CUkXFA5cLHumn88>

2. 使用LlamaIndex智能体框架构建。

3. 用Mermaid工具或其他工具，绘制一副框图来描述该 workflow。

任务4：构建一个多Agent智能路由 workflow

在上一任务中，我们实现了“单一路线的AI workflow”。接下来，本任务将引入 **多智能体协作** 的概念。你需要设计一个至少包含两个Agent的系统，利用 **智能路由 (Intelligent Routing)** 和 **ReAct范式 (Reason+Action+Observation)** 来动态分配任务并执行。

任务要求

1. 首先，你需要构建以下3种智能体

1. 一个 **路由Agent (Router Agent)**：负责理解用户输入意图，并智能分发任务。

2. 两个规定好的业务Agent：

- **数学Agent (MathAgent)**：处理用户输入的数学题，并给出解答过程与答案。我们这里给这个数学Agent一个乘法工具，用于计算两数相乘。
- **搜索Agent (SearchAgent)**：能根据用户的查询来进行联网搜索，并根据搜索到的结果回答问题。（这里可以直接使用任务3中的成果）。

3. 一个 **总结输出Agent**：用于总结最终的答案，输出给用户。

设计重点：

- 路由必须依靠 **LLM语义推断**（而非简单if-else）来判断该调用 `MathAgent` 还是 `SummaryAgent`。
- 两个业务Agent需采用 **ReAct 思维模式**（思考-行动-观察-总结），即在回答时显式展现推理过程。

- 不需要外部API调用，全部用LLM本身就能完成任务。

2. 接着，实现一个多Agent workflow。

工作流逻辑

1. 用户输入

- 示例1：“请帮我计算123乘以456的结果”
- 示例2：“请帮我总结这段话的内容：.....”

2. 路由Agent

- 解析用户输入 → 推断意图
- 如果是数学计算 → 分流到 `MathAgent`
- 如果是摘要任务 → 分流到 `SearchAgent`

3. 业务Agent执行

- **MathAgent (数学Agent)**
 - ReAct范式：
 - 思考 (Reasoning)：分析用户输入，识别数学运算类型
 - 行动 (Action)：执行计算 (可以直接用Python计算 or 让模型做算术)
 - 观察 (Observation)：核对结果是否合理
- **SearchAgent (搜索Agent)**
 - 使用第二问中实现的搜索Agent

4. 总结Agent总结最终答案，结果返回

- 总结Agent输出最终结果给用户
- 如果业务Agent未能正确处理任务 → 可以反馈回 `路由Agent` 重新判断

输出示例

```
=====
测试用例 1
=====

Running step route_task
用户输入: 请帮我计算1234567乘以456789的结果

-----
1. 路由 Agent 正在分析任务类型...
路由决策: MATH

-----
Step route_task produced event RoutingEvent
Running step generate_final_output
2. 数学 Agent 正在处理...
数学 Agent 回答: 1234567乘以456789的结果是563936625363。

-----
3. 总结 Agent 正在总结最终答案...

-----
Step generate_final_output produced event FinalOutputEvent
```

Running step complete_workflow

最终答案：

1234567乘以456789的结果是563936625363。

Step complete_workflow produced event StopEvent

[StreamEvent] StopEvent:

workflows执行完成，结果：1234567乘以456789的结果是563936625363。

测试用例 2

Running step route_task

用户输入：请帮我总结这段话的内容：人工智能是计算机科学的一个分支，它企图了解智能的实质，并生产出一种新的能以人类智能相似的方式做出反应的智能机器。该领域的研究包括机器人、语言识别、图像识别、自然语言处理和专家系统等。

1. 路由 Agent 正在分析任务类型...

路由决策：SUMMARY

Step route_task produced event RoutingEvent

Running step generate_final_output

2. 摘要 Agent 正在处理...

摘要 Agent 回答：人工智能是计算机科学的一个分支，旨在理解智能的本质并创造能够模拟人类智能的机器。其研究领域广泛，涵盖机器人、语言识别、图像识别、自然语言处理和专家系统等。

3. 总结 Agent 正在总结最终答案...

Step generate_final_output produced event FinalOutputEvent

Running step complete_workflow

最终答案：

人工智能是计算机科学的一个分支，旨在理解智能的本质并创造能够模拟人类智能的机器。其研究领域广泛，涵盖机器人、语言识别、图像识别、自然语言处理和专家系统等。

Step complete_workflow produced event StopEvent

[StreamEvent] StopEvent:

workflows执行完成，结果：人工智能是计算机科学的一个分支，旨在理解智能的本质并创造能够模拟人类智能的机器。其研究领域广泛，涵盖机器人、语言识别、图像识别、自然语言处理和专家系统等。

加分项

1. 使用LlamaIndex智能体框架。
2. 每个Agent都有结构化的系统提示词和格式化的输出。
3. 使用Mermaid或者其他工具来绘制一个框图，展示这个工作流的工作流程。

进阶部分

下面任务为24级同学选做。可以在下面任务中二选一，也可以全做。

任务5（可选）：构建一个带有RAG知识库的Agent

在前几个任务里，我们的智能体主要依赖 LLM 自身的语言理解与推理能力。

但当涉及到 **专业知识领域** 的知识问答，LLM 常常会出现“幻觉”（编造答案）。

为了解决这个问题，本任务要求你实现一个包含 **RAG (Retrieval-Augmented Generation)** 的知识型 Agent：

- 能够基于给定的《多元分析学》教材文本 搭建知识库
- 用户向Agent提问时，Agent依赖 **检索 + 生成** 来保证答案的准确性
- 最终完成一个 **基于教材问答/摘要/复习的AI助理**

任务要求

1. 构建一个基于RAG的知识库检索工具
 - 使用给定的《多元分析学》教材 markdown 文件作为语料：https://github.com/Gonghysin/Multivariate_analysis_markdown/blob/main/%E5%A4%9A%E5%85%83%E5%88%86%E6%9E%90%E5%AD%A6_markdown.md
 - 将文本切分为合适的 chunk（例如 500~1000 字）
 - 将每个片段用Embedding模型向量化存入本地检索库。
2. 将该工具添加到一个Agent里。然后要求实现与这个Agent连续、有上下文记忆的对话。
 - 测试样例：
 - “请问《多元分析学》的作者是谁？”
 - “请问Abel第二定理的内容是什么？”
 - LLM基于检索片段生成回答。

示例输出

Q: 请问《多元分析学》的作者是谁？
A: 《多元分析学》由黄永忠老师编写了第1章、第2章、第6章、第7章及第4章的第7节，刘艳红老师编写了第3章，韩志斌老师编写了第4章、第5章。全书由黄永忠老师统稿和润色。
Q: 请问Abel第二定理的内容是什么？
A: Abel第二定理指出，如果一个幂级数 $\sum a_n x^n$ 的收敛半径 R 是有限且大于零的，那么该级数在 $(-R, R)$ 上是内闭一致收敛的。此外，如果该幂级数在 $x=R$ 处收敛（且 $R \neq \infty$ ），那么它在 $(-R, R]$ 的任意闭子区间上都是一致收敛的。

加分项

1. 使用LlamaIndex智能体框架。
2. 使用ollama本地部署embedding模型。

Ollama教程：<https://zhuanlan.zhihu.com/p/17482899149>

推荐使用Embedding模型：dengcao/Qwen3-Embedding-4B:Q8_0

3. ★使用Docker部署的Qdrant向量储存数据库来储存向量数据

- docker教程：<https://www.runoob.com/docker/docker-tutorial.html>
- Qdrant Docker教程：<https://qdrant.tech/documentation/guides/installation/#docker>

任务6（可选）：微调模型

有的时候，我们希望模型能在某一个垂直领域有更强的能力，而且这些能力往往是RAG不足以实现的。例如，当我们需要一个作者Agent的时候，我们希望这个Agent能拥有优美的文风。如果仅仅是在“请你用优美的文风写作”，这样的效果往往差强人意。

所以我们希望，如果我们能利用手上已有的语料数据，例如某一位自己喜欢的作家的文本，用于去微调训练一个自己专属的LLM，从而达到自己想要的输出风格。这时就要用到“微调模型”技术了。

为了解决这个问题，本任务要求你实现一个以基于QLoRA微调技术微调过后的LLM为基础的Agent，能进行可拓展的角色扮演。

任务要求

1. 学习以下概念

- 微调模型（fine-tune）
- LoRA微调

2. 学习如何租用AutoDL云算力服务器

- 租用服务器教程：https://api.autodl.com/docs/quick_start/
 - 推荐显卡选择4090
- 学习实用Vscode的Remote SSH功能来链接AutoDL云服务器：https://blog.csdn.net/qq_38198286/article/details/127886049
- 在服务器中练习linux系统的几个常用命令：<https://www.runoob.com/w3cnote/linux-common-command-2.html>

3. 在AutoDL服务器上本地部署Qwen3-14B大模型

- 模型链接：<https://huggingface.co/Qwen/Qwen3-14B>
- 教程：<https://blog.csdn.net/Z2781067882/article/details/140611101>
- 用这个本地部署的模型，实现「任务2」中的简单有记忆对话Agent
- 推荐使用Llama-Factory进行模型部署（使用非常方便）：<https://github.com/hiyouga/LLaMA-Factory>

4. 微调Qwen3-14B大模型

- 微调数据集使用：https://huggingface.co/datasets/BigPancake01/roleplayLLM_Chinese
- 推荐使用Llama-Factory微调框架进行微调
- 最后展示和微调后的模型进行对话的记录

示例输出

System Prompt:

以下是一段关于旅行者与可莉之间的对话。你需要扮演其中的可莉与旅行者对话。

可莉的信息：可莉是米哈游旗下游戏《原神》中的登场角色，她性格纯真好奇，对外界的一切都充满爱意和探索欲。她热爱爆炸物，对此抱有极大的热忱和创造力，但也因此时常闯祸，不过每次事后都会愧疚地努力弥补。可莉天性贪玩，不计后果，但又极具天赋，一旦才能用对地方，就能爆发出惊人的实力。她对家人和朋友充满深厚的感情，骑士团是她的第二个家，而妈妈则是她的偶像和榜样。可莉的乐观、勇敢和坚持不懈，让她在冒险的道路上不断前行，即使面对困难和挑战，也永远不会放弃自己的梦想和“礼物”——神之眼。

旅行者的信息：旅行者是米哈游出品游戏《原神》中的主角，作为一对跨越诸多世界的双子之一，旅行者与血亲远渡重天，降临名为「提瓦特」的大陆，希望能与这个世界和谐相处。然而，陌生的神灵拦在面前，带走了你唯一的血亲，并将你封印，陷入漫长的沉眠。再度醒来时，天地已变，战火平息，熟悉的景象不复存在，你孤身一人踏上旅途，寻找那位神灵的踪迹。在旅途中，你遇到了旅伴派蒙，并得知此世由七位神灵以「尘世七执政」之名统治七国。你将第一站定为风神建立的自由城邦蒙德，却目睹了深渊教团与至冬国冰之女皇的双重威胁。你与风神化身吟游诗人一同行动，解救被腐化的东风之龙，却在巨龙的瞳中看到了统领深渊之人——那位曾与你一同跨越世界的血亲。旅行者的旅程不仅是对抗危机与寻找亲人的冒险，更是对提瓦特世界真相的探索。你无法获得「神之眼」，却以独特的力量引导元素之力，见证了凡人的渴望与神明的意志。在穿行于诸多世界的旅途中，旅行者不断思考着生命的本质与命运的意义，以坚定的步伐迈向未知的未来，最终将登上「神」之座，守护这个不再灼烧的世界。

Input:

有什么想要分享...

Output:

可莉知道，骑士团的墙是不能炸的。虽然打通了能从禁闭室出去很方便，但凯亚哥哥说，这样做了以后，琴团长恐怕会让我再也见不到第二天的太阳...

测试提交方式

重要提示：本次作业提交方式已更新！

你将不再需要将代码推送到 **GitHub**。所有提交内容将打包成一个ZIP文件并通过邮件发送。但项目结构和模板仍需参考 **GitHub** 示例仓库。

1. 代码获取与结构要求

1. **项目初始化**：请从以下示例仓库中获取项目结构和模板，并在本地进行开发。无需在 **GitHub** 上创建自己的仓库或进行提交。
 - 示例仓库链接：https://github.com/Gonghysin/comsen_test_example
2. **本地开发分支**：建议你的所有本地代码开发都在 `main` 分支上进行，以保持结构清晰。
3. **目录结构**：请务必遵循以下结构，将各任务代码存放于不同文件夹。

```
your_project_folder/ # 这是你要打包的项目根文件夹
├─ task_1/
├─ task_2/
...
├─ README.md
├─ requirements.txt
├─ .gitignore
└─ .env # 此文件本地存放，不可上传
```

2. 开发环境与视频要求

- **Python版本**：统一使用 **3.11**。
- **API Key管理**：严禁硬编码，所有Key须通过 `.env` 文件读取。
- **视频录制**：每个任务录制一个演示视频，命名为 `task1.mp4`, `task2.mp4` ...，总时长 **不超过5分钟**。

3. 最终提交步骤

1. **创建说明文档** 在本地创建一个名为 `submit.md` 的文档（无需随项目代码上传），内容包括：

- 你的制作思路、遇到的问题和创新点。

markdown语法教程：<https://markdown.com.cn/basic-syntax/>

推荐markdown编辑器：Obsidian, Typora

2. **打包文件** 将以下所有需要提交的文件和文件夹打包成一个 **ZIP 压缩包**：

- 你的项目代码文件夹（例如 `your_project_folder/`，其中包含所有任务代码、`README.md`、`requirements.txt`、`.gitignore` 等）。请务必确保 `.env` 文件已从打包的文件中移除。
- 你创建的 `submit.md` 文档。
- 所有任务的演示视频（`.mp4` 格式）。

请确保压缩包内容层级清晰，例如：

```
submission.zip
├─ your_project_folder/ # 你的整个项目代码
│   ├── task_1/
│   ├── task_2/
│   └─ ...
├─ submit.md
├─ task1.mp4
├─ task2.mp4
└─ ...
```

3. **发送邮件**

- 发送压缩包到邮箱：hayisaka@163.com
- 邮件标题格式：`Comsen提交-专业-班级-姓名-学号`

